

**Desarrollo de un sistema de bioacceso mediante
voz para castellano rioplatense en hardware de
bajo costo.**

*Tesis final presentada para obtener el título de Ingeniero de Sonido de la
Universidad Nacional de Tres de Febrero (UNTREF)*

TESISTA: Gonzalo Rios (40.078.963)

TUTOR/A: Ing. Paula Ortega Riera

COTUTOR/A: -

AGRADECIMIENTOS

En primer lugar dar gracias a la Universidad Nacional de Tres de Febrero (UNTREF), a su Rector Martín Kaufmann, a todo su personal docente y no docente. Por promover un espacio ideal para el desarrollo de ideas y nuevos pensamientos y brindar a todos y cada uno de los alumnos, de esta casa de altos estudios, todos los recursos que esta institución dispone. Esta investigación no hubiera sido posible sin una formación académica acorde, por este motivo debo extender mi agradecimiento a los docentes de la carrera de Ingeniería de Sonido de la UNTREF, a su coordinador Ing. Alejandro Bibondo, que siendo la primera carrera de estas características del país, es muy importante contar con un cuerpo docente afín a las exigencias que este desafío propone, prestando su dedicación y vocación de enseñar. Un especial agradecimiento por la participación de esta tesis a la tutora Ing. Paula Ortega Riera, que supo transmitirme sus conocimientos y ayudarme a organizarme y fijarme un rumbo concreto y delineado, disponiendo desmedidamente de su tiempo.

Por último y no menos importante, quiero dar un afectuoso y cálido agradecimiento a mi familia.

DEDICATORIA

.

Elegir el motivo de la dedicatoria (orientativo).

ÍNDICE DE CONTENIDOS

RESUMEN	VIII
ABSTRACT	IX
1 INTRODUCCIÓN	1
1.1 FUNDAMENTACIÓN	1
1.2 OBJETIVOS	2
1.2.1 Objetivo general	2
1.2.2 Objetivos específicos	2
1.3 ESTRUCTURA DE LA INVESTIGACIÓN	3
2 MARCO TEÓRICO	4
2.0.1 Modelos de identificación del hablante	5
2.0.2 Embeddings	6
2.0.3 Espectrograma de Mel y MFCC	6
3 ESTADO DEL ARTE	7
4 DESARROLLO	9
4.1 METODOLOGÍA	9
5 RESULTADOS Y ANÁLISIS	10
5.1 RESULTADOS Y ANALISIS	10
6 CONCLUSIONES	11
7 LÍNEAS FUTURAS DE INVESTIGACIÓN	12
BIBLIOGRAFÍA	13

Índice de Figuras

Índice de Tablas

RESUMEN

Pendiente: Su contenido no debe superar una página. Se indicarán los objetivos del trabajo, los métodos y resultados principales. A dos espacios debajo del resumen, en la misma página, se colocarán hasta 5 palabras clave que identifican los contenidos del trabajo.

Palabras Clave:

ABSTRACT

Ídem que para castellano.

Keywords:

1. INTRODUCCIÓN

1.1. FUNDAMENTACIÓN

En la actualidad, la biometría de voz se ha consolidado como un mecanismo de autenticación robusto, permitiendo el control de acceso sin contacto y mejorando la seguridad en múltiples entornos. Tradicionalmente, estos sistemas han dependido de arquitecturas basadas en la nube o de procesadores de alto rendimiento debido a la complejidad computacional que requiere la extracción de características acústicas y la inferencia mediante modelos de aprendizaje automático. Sin embargo, el auge del paradigma Edge Computing y, específicamente, del TinyML (Machine Learning en el borde), ha posibilitado la migración de estos algoritmos hacia dispositivos con recursos más limitados (Rayen et al., 2021). En este marco, la combinación de microcontroladores de bajo costo y consumo, junto con micrófonos con tecnología MEMS (Sistemas Microelectromecánicos), representa una solución de hardware óptima y escalable para la implementación de sistemas de bioacceso autónomos e integrables en el ecosistema de la Internet de las Cosas (IoT) (Warden y Situnayake, 2019).

Si bien la literatura documenta avances significativos en el reconocimiento de locutor (SR) (Fenu et al., 2021), existe un vacío crítico en la intersección de la optimización de hardware y la sociolingüística aplicada. La inmensa mayoría de los conjuntos de datos vocales (corpus) y los modelos pre entrenados disponibles comercial o académicamente están sesgados hacia idiomas hegemónicos, como el inglés, o hacia variantes estandarizadas del español, como español latinoamericano "neutro". La variante del castellano rioplatense posee características fonológicas, prosódicas y de articulación únicas, tales como el yeísmo y la aspiración de la /s/ implosiva (Colantoni, 2006). Al cuantizar (conversión de 32 bits a 8 bits) y comprimir redes neuronales para que operen dentro de las limitaciones de memoria (SRAM/Flash) y procesamiento de un microcontrolador, los modelos tienden a perder precisión, y esta degradación afecta de manera desproporcionada a las variantes dialectales subrepresentadas en el entrenamiento original. Actualmente, no existe un marco de desarrollo estandarizado que garantice la eficacia de sistemas de bioacceso offline sobre hardware restrictivo calibrado específicamente para la fonética rioplatense.

A partir de la problemática expuesta, la presente investigación se articula en torno a la

siguiente pregunta: ¿De qué manera se puede ajustar y optimizar un modelo de aprendizaje automático para la detección y verificación del hablante, implementado en microcontroladores de bajos recursos mediante micrófonos MEMS, que garantice un alto nivel de precisión y seguridad operando exclusivamente con locutores de dialecto castellano rioplatense?

El desarrollo de esta investigación se justifica por su doble aporte: tecnológico y sociocultural. Desde la perspectiva tecnológica, el proyecto llenará un punto vacío en la ingeniería de sistemas embebidos al proponer una metodología documentada para la extracción de características acústicas (como coeficientes MFCC), el aumento y tratamiento de datos para mitigar el ruido inherente a los micrófonos MEMS (Ko et al., 2015), y el diseño de arquitecturas de inferencia ligeras que logren alta precisión frente a variaciones fonéticas locales, superando las limitaciones intrínsecas del hardware. Desde una perspectiva sociocultural y de usabilidad, este trabajo combate el sesgo lingüístico en la Inteligencia Artificial. Al desarrollar tecnología de acceso biométrico que reconozca y valide las particularidades del castellano rioplatense, se democratiza el acceso a la seguridad tecnológica de vanguardia, garantizando que los usuarios locales interactúen con dispositivos que se adaptan a su identidad lingüística, y no a la inversa.

1.2. OBJETIVOS

1.2.1. Objetivo general

En lo que compete a esta investigación, el objetivo general de la misma abarca desarrollar un sistema destinado al control de acceso de personas por medio de reconocimiento de voz en castellano rioplatense, implementado en hardware de bajo costo

1.2.2. Objetivos específicos

- Implementar un algoritmo para la extracción del descriptor MFCC (Mel-Frequency Cespectral Coefficient).
- Ajuste fino (FT) en PC para su posterior cuantización.
- Evaluar la tasa de error (EER) post cuantización.

- Transferir el modelo entrenado al microcontrolador.
- Comparar el EER obtenido entre el dispositivo y la PC.
- Confeccionar una interfaz de usuario para que el administrador del sistema pueda generar nuevos enrolamientos de usuarios.
- Realizar pruebas de concepto con usuarios que no se hayan empleado para el entrenamiento del modelo.

1.3. ESTRUCTURA DE LA INVESTIGACIÓN

En esta sección se detallará cómo se dividen los distintos apartados de la investigación.

2. MARCO TEÓRICO

La voz humana es una señal biológica compleja resultante de la interacción dinámica entre la aducción y vibración de los pliegues vocales y la emisión de flujo de aire pulmonar a través de estructuras resonantes (Lee, 2021). Como característica biométrica, posee tanto rasgos físicos (fisiológicos) como conductuales que la hacen única para cada individuo. En el ámbito de la seguridad, el reconocimiento de voz se divide principalmente en dos tareas: la identificación de hablante, que determina la identidad en una comparación de uno a muchos, y la verificación de hablante, que confirma una identidad declarada mediante un mapeo uno a uno (Shivani y Brij, 2017). Estos procesos pueden ser dependientes del texto o independientes del mismo, siendo estos últimos más versátiles pero complejos de procesar en entornos prácticos (Costantini et al., 2023).

El procesamiento de voz en sistemas embebidos requiere transformar la señal de audio cruda en representaciones paramétricas compactas que reduzcan la dimensionalidad sin perder información discriminativa. Las técnicas más prevalentes incluyen a los Coeficientes Cepstrales en la Escala de Mel (MFCC), que representan el estándar al aproximar la respuesta no lineal del sistema auditivo humano mediante filtros espaciados logarítmicamente. Son altamente efectivos para modelar la envolvente espectral y el tono. Por otro lado, también existen los Coeficientes de Predicción Lineal (LPCC), que se basan en el sistema articulatorio humano (tracto vocal) y modelan la señal como una combinación lineal de muestras pasadas. Son computacionalmente eficientes y útiles en tareas de frase fija. También, se puede contar con características de dominio temporal (ZCR y STE), donde la tasa de cruce por cero (ZCR) y la energía de tiempo corto (STE) son descriptores de baja complejidad computacional ideales para dispositivos con recursos extremadamente limitados, como los microcontroladores PIC (Shili et al., 2025).

La implementación de modelos de aprendizaje automático directamente en microcontroladores (Edge AI) permite reducir la latencia, mejorar la privacidad y eliminar la dependencia de la conectividad en la nube (Roharia, n.d.). En cuanto a los tipos de arquitectura, las redes neuronales convolucionales (CNN) son altamente efectivas al tratar los espectrogramas de voz como imágenes para identificar patrones locales (Costantini et al., 2023). Por otro lado, los Perceptrones Multicapa (MLP) o redes feed-forward (FNN) ofrecen un equili-

brio óptimo entre precisión y ligereza para tareas de clasificación binaria en hardware restringido. En cuanto a la optimización, se emplea el método llamado Cuantización. El mismo es empleado para adaptar modelos complejos a la memoria SRAM y Flash limitada de un microcontrolador, que convierten pesos de punto flotante de 32 bits a enteros de 8 bits (int8), reduciendo el tamaño del modelo hasta cuatro veces con una pérdida mínima de precisión (Evans, 2026).

El rendimiento de los sistemas de biometría vocal es sensible a variables ambientales y biológicas como:

- Relación Señal-Ruido (SNR): la calidad del micrófono MEMS es crítica; micrófonos con alto SNR permiten capturar sutilezas de la voz incluso a niveles bajos de presión sonora (SPL), mientras que un bajo SNR degrada significativamente la tasa de error de palabra (WER).
- Variabilidad biológica y envejecimiento: el envejecimiento fisiológico altera las estructuras laríngeas, modificando la frecuencia fundamental (F0), el jitter y el shimmer. Estadísticas de orden superior, como la asimetría (skewness) y la curtosis, han demostrado ser predictores clave para distinguir entre voces jóvenes y ancianas.
- Vulnerabilidades de Seguridad: Los sistemas son susceptibles a ataques de replaying y clonación de voz mediante IA generativa. Como contramedida, se implementan técnicas de detección de vitalidad (liveness detection) y autenticación multifactor (MFA) combinando voz con otros rasgos biométricos.

La eficacia de un sistema biométrico se cuantifica mediante la tasa de falsa aceptación (FAR), la tasa de falso rechazo (FRR) y la tasa de igual error (EER) (Brydinskyi et al., 2024). El EER representa el punto donde FAR y FRR son iguales; un valor menor indica una mayor precisión global del sistema. En aplicaciones de comercio electrónico o control de acceso, estas métricas deben balancearse según la criticidad de la seguridad frente a la conveniencia del usuario.

2.0.1. Modelos de identificación del hablante

En este apartado se detallará acerca de la arquitectura de los distintos tipos de modelos que se encuentran en el mercado.

2.0.2. Embeddings

En este apartado se detallará acerca de la herramienta fundamental que es para esta investigación la utilización de embeddings.

2.0.3. Espectrograma de Mel y MFCC

En este apartado se detallará acerca del concepto fundamental para la extracción de información acústica de la señal que ingresa al sistema.

3. ESTADO DEL ARTE

El desarrollo de sistemas de control por voz en dispositivos de borde ha experimentado un avance significativo con la evolución de la serie de microcontroladores ESP32. Actualmente, el ESP32-S3 se posiciona como el estándar para estas aplicaciones debido a su arquitectura de doble núcleo Xtensa LX7 y, fundamentalmente, por la inclusión de extensiones de instrucciones de inteligencia artificial que aceleran las operaciones de redes neuronales (Kumar, 2026). Esta capacidad de procesamiento local permite un cambio de paradigma hacia la inteligencia en el borde, buscando minimizar la latencia y maximizar la privacidad de los datos al mantener los procesamiento biométricos de voz dentro del dominio del hardware del dispositivo.

En cuanto a la captura acústica, se observa una transición desde los micrófonos analógicos tradicionales hacia los micrófonos MEMS digitales, destacando el modelo INMP441. Estos dispositivos integran un sensor acústico, un preamplificador y un convertidor analógico a digital (ADC) de 24 bits, entregando una señal digital directamente a través de la interfaz I2S (Inter-IC Sound). Este enfoque elimina la vulnerabilidad al ruido inherente a las señales analógicas. No obstante, investigaciones en entornos educativos todavía emplean soluciones analógicas como el módulo MAX9814 con control automático de ganancia para simplificar el diseño de circuitos y reducir costes (Nguyen, 2025).

El procesamiento de voz se divide actualmente en dos grandes arquitecturas: local e híbrida. El reconocimiento de voz local u offline utiliza marcos de trabajo como ESP-Skainet, que emplea los motores WakeNet para el monitoreo continuo de palabras de activación y MultiNet para el reconocimiento de hasta 200 comandos locales (Joseph, 2026). Complementariamente, plataformas como Edge Impulse facilitan el despliegue de modelos de aprendizaje automático personalizados (TinyML), entrenados para tareas específicas de detección de palabras clave con baja latencia. Por otro lado, las arquitecturas híbridas delegan las tareas computacionalmente intensivas, como el procesamiento de lenguaje natural, a servicios en la nube como OpenAI Whisper y ChatGPT (GPT-3.5-turbo), permitiendo que microcontroladores económicos realicen interacciones complejas de voz a texto y texto a voz (Nguyen, 2025).

La integración con el Internet de las Cosas (IoT) se apoya predominantemente en el

protocolo MQTT (Transporte de telemetría de colas de mensajes), valorado por su ligereza y eficiencia en redes con ancho de banda limitado. El uso de MQTT permite que el ESP32 actúe como un cliente que publica eventos de acceso concedido o se suscribe a comandos remotos, integrándose con ecosistemas como Home Assistant. Investigaciones emergentes introducen el protocolo Model Context Protocol (MCP), que actúa como un lenguaje universal para que modelos de IA interactúen directamente con el hardware, descubriendo capacidades del dispositivo y ejecutando acciones físicas como el control de cerraduras de solenoide. En el ámbito de la seguridad, el estado del arte incluye sistemas avanzados de verificación de identidad mediante embeddings de voz (como ECAPA-TDNN o x-vectors) y mecanismos de detección de vitalidad (liveness detection) como los sistemas Void y Live-Probe, diseñados para prevenir ataques de repetición mediante el análisis de la potencia espectral de la voz humana frente a altavoces. A nivel de hardware, se enfatiza la implementación de Secure Boot y cifrado de flash para proteger la integridad del firmware y las plantillas biométricas almacenadas (Jain, 2026).

Finalmente, la implementación práctica enfrenta desafíos críticos en la gestión de recursos. Las limitaciones de la memoria SRAM (normalmente 512 KB) obligan a optimizar el uso del heap y emplear técnicas de gestión de tareas mediante FreeRTOS (Sistema operativo en tiempo real) para manejar de forma concurrente la captura de audio y la comunicación de red (Nguyen, 2025). Asimismo, la estabilidad eléctrica es un factor determinante, requiriendo circuitos de protección contra caídas de tensión causadas por la activación de actuadores de alta corriente como solenoides o ventiladores.

4. DESARROLLO

4.1. METODOLOGÍA

La primera etapa de la investigación se centro en la búsqueda de los distintos modelos destinados a la verificación de hablantes.

En cuanto a este apartado, estuve trayando en la recopilación de bibliografía para determinar qué modelo aplicado a la identificación de hablantes es apropiado emplear. Sobre todo, qué tecnica es necesaria aplicar para la utilización del modelo en formato ligero para su ejecución dentro del microcontrolador. Recién se pudo detallar que el modelo a emplear sea el ECAPA-TDNN, tanto con su versión para PC como su versión ligera, ECAPA-TDNNLite para microcontrolador. Según la bibliografía revisada, la idea es emplear uno de los dos para el enrolamiento de nuevos usuarios y el otro para la verificación de hablantes. Dado a que según el paper de referencia, de esta manera se consigue menor EER, es decir, mayor precisión.

5. RESULTADOS Y ANÁLISIS

5.1. RESULTADOS Y ANALISIS

6. CONCLUSIONES

En las conclusiones del Plan de Investigación, debe plantearse cómo será la exposición de los resultados y qué es lo que se espera obtener en resumen de las pruebas que se realicen.

7. LÍNEAS FUTURAS DE INVESTIGACIÓN

Este trabajo pretende contribuir a la unificación de criterios en el diseño y evaluación de cadenas de preprocesado, lo que facilitará la identificación de las configuraciones más adecuadas para distintos casos de uso. Entre las líneas futuras de investigación se destacan, en particular, el desarrollo de modelos de denoising o speech enhancement personalizados: mediante técnicas de adaptación, dichos modelos buscarían aproximar conjuntos de grabaciones diversas hacia el dominio acústico del corpus con el que fue entrenado el modelo TTS, aumentando así la robustez y la fidelidad de la síntesis en condiciones reales.

BIBLIOGRAFÍA

- Brydinskyi, V., Khoma, Y., Sabodashko, D., Podpora, M., Khoma, V., Konovalov, A., & Kostiak, M. (2024). Comparison of Modern Deep Learning Models for Speaker Verification. *Applied Sciences*, 14(4), 1329. <https://doi.org/10.3390/app14041329>
- Colantoni, L. (2006). Micro and macro sound variation and change in Argentine Spanish. En *Current Issues in Linguistic Theory* (pp. 91-102, Vol. 274). John Benjamins Publishing Company.
- Costantini, G., Cesarini, V., & Brenna, E. (2023). High-Level CNN and Machine Learning Methods for Speaker Recognition. *Sensors*, 23(7), 3461. <https://doi.org/10.3390/s23073461>
- Evans, C. (2026). How to Deploy AI on a Microcontroller? <https://www.ampheo.com/blog/how-to-deploy-ai-on-a-microcontroller>
- Fenu, G., Lafhouli, H., & Marras, M. (2021). Fair Voice Biometrics: Impact of Demographic Imbalance on Group Fairness in Speaker Recognition. *2021 IEEE International Joint Conference on Biometrics (IJCB)*.
- Jain, J. (2026). ESP32 Secure Boot and Flash Encryption: Protect Your Device. <https://zbotic.in/esp32-secure-boot-and-flash-encryption-protect-your-device/>
- Joseph, J. (2026). Voice Activated LED Controller with Touch Interface Using ESP32-S3 Box 3. <https://circuitdigest.com/microcontroller-projects/voice-activated-led-controller-with-touch-interface-using-esp32-s3-box-3>
- Ko, T., et al. (2015). Audio augmentation for speech recognition. *Sixteenth Annual Conference of the International Speech Communication Association*.
- Kumar, R. (2026). Pocket Size ESP32 AI Voice Assistant With Xiaozhi. <https://maker.pro/arduino/projects/pocket-size-esp32-ai-voice-assistant-with-xiaozhi>
- Lee, J.-Y. (2021). Classification between Elderly Voices and Young Voices Using an Efficient Combination of Deep Learning Classifiers and Various Parameters. *Applied Sciences*, 11(21), 9836. <https://doi.org/10.3390/app11219836>
- Nguyen, L. (2025). *Smart voice AI system for educational IOT applications using ESP32-S3* (inf. téc.). University of Applied Sciences.
- Rayen, C. A., et al. (2021). A Review on TinyML: State-of-the-art and Prospects. *Journal of King Saud University – Computer and Information Sciences*.

- Roharia, A. (n.d.). HP: Bringing Voice Control to Earbuds & Headsets. <https://www.edgeimpulse.com/case-studies/bringing-voice-control-to-earbuds-headsets>
- Shili, M., Hammedi, S., Gawanmeh, A., & Nouri, K. (2025). Embedded Implementation of Real-Time Voice Command Recognition on PIC Microcontroller. *Automation*, 6(4), 79. <https://doi.org/10.3390/automation6040079>
- Shivani, J., & Brij, K. (2017). Comparative study of voice print Based acoustic features: MFCC and LPCC. *International Journal of Advanced Engineering, Management and Science*, 3(4). <https://doi.org/10.24001/IJAEMS.3.4.5>
- Warden, P., & Situnayake, D. (2019). *TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers*. O'Reilly Media.

ANEXO I

ANEXO I